

Doodle Jump DQN 与 Double DQN 个人报告

姓名：_____ 学号：_____ 课程：2026 秋研究生强化学习 模块：B

模块目标与结论

本模块实现两个离策略价值算法，在相同环境、网络和训练预算下比较 TD 目标的动作选择方式。DQN 和 Double DQN 的当前窗口得分分别为 18476.5 ± 1145.6 与 18584.2 ± 1969.7 ，平均差 107.7 分，约 0.58%。差值远小于种子间波动，本实验支持两者表现接近，不能宣称 Double DQN 显著更好或在所有小游戏上必然更优。

本报告描述对应模块的技术成果、实现依据与验证方法。模块编号表示分工范围；实际参与的实现、复核、实验和写作工作由成员在末页据实填写。项目结果来自自己保存的配置、权重与逐局记录。

价值函数与训练数据

$Q(s,a)$ 表示在当前局部观测下执行动作并继续遵循策略的折扣回报估计。环境输入 209 维结构信息，输出 3 个 Q 值，对应左、不动、右。训练用 epsilon-greedy 探索收集转移；评测使用 argmax 动作，不把评测地图放回经验回放。

经验回放容量 100000，从缓冲区随机取小批量，降低连续转移的相关性并重复利用数据。目标网络在若干决策后复制在线网络参数，使 TD 目标在同步间隔内相对稳定。它仍会随训练变化，不能认为训练目标是固定标签。

网络与参数量

层	参数量计算
209→128	$209 \times 128 + 128 = 26880$
128→128	$128 \times 128 + 128 = 16512$
128→3	$128 \times 3 + 3 = 387$
合计	43779 个可训练参数

两个隐藏层使用 ReLU。两算法参数量相同，没有用更大网络作为 Double DQN 的额外优势。输入向量维数是特征个数，参数量是网络中需要学习的权重和偏置数量，二者不同。

DQN 与 Double DQN 的目标

DQN 使用 $y = r + \gamma \times (1 - \text{terminal}) \times \max_a Q_{\text{target}}(s_{\text{next}}, a)$ 。Double DQN 先由在线网络求 $a_{\text{star}} = \operatorname{argmax}_a Q_{\text{online}}(s_{\text{next}}, a)$ ，再用 $y = r + \gamma \times (1 - \text{terminal}) \times Q_{\text{target}}(s_{\text{next}}, a_{\text{star}})$ 评估。当前损失均为 $\text{Huber}(Q_{\text{online}}(s, a), y)$ 。TD 目标在反向传播时停止梯度。

DQN 用同一组目标 Q 值完成选择与评估，噪声经 max 操作可能产生高估。Double DQN 分开这两步以减轻该机制，但不能保证 Q 完全无偏。当前实验没有估计真实 Q 或独立测量高估偏差，不能将得分差直接当作偏差的因果证据。

优化与终止处理

对回放样本前向计算 $Q(s, a)$ 和下一状态目标，求 Huber 损失，清除旧梯度，反向传播，按范数上限裁剪后执行 Adam 更新。梯度调整的是估值网络，游戏物理和地图生成规则不随梯度改变。每 2000 次决策把在线参数复制到目标网络。

真实死亡使 TD 目标只剩即时奖励；1500 次决策时限是截断，保留下一状态 bootstrap。缓冲区只把 terminated 作为屏蔽字段，不能统一使用 terminated OR truncated。重置后的新状态也不能被错误当作上一回合的下一状态。

超参数	DQN 与 Double DQN 共用设置
gamma 与学习率	0.99; 0.0005
replay 与 batch	100000; 128
开始学习与更新周期	2500 决策后; 每 4 决策更新一次
目标同步与梯度裁剪	每 2000 决策; 范数上限 10
epsilon 探索	1.0→0.05, 在 600000 决策内线性下降
预算与种子	各 1000000 决策; 42、59、143

一次决策最多 4 个物理帧，100 万决策不是 100 万物理帧，也不是 100 万次梯度更新。死亡会提前结束动作重复，实际帧数以 status.json 为准。

实验协议与真实结果

训练地图种子 ≥ 1000000 。验证地图 10000-10019，每约 5 万决策评测，按验证均分选择 best.pt；final.pt 独立保存。主测试固定 61000-61099，每个训练种子 100 张新地图，权重冻结后不按测试成绩调参。

算法	当前窗口得分 $\pm$ SD	最高攀升 px	得分 ≥ 3000	截断
DQN	18476.5 $\pm$ 1145.6	3737.7	83.7%	19.7%
Double DQN	18584.2 $\pm$ 1969.7	3744.3	85.7%	19.7%

先对各训练种子的 100 局求均值，再对三个均值求平均和样本 SD。它不是 300 张地图的置信区间，独立训练重复数量是 3。得分 ≥ 3000 只是预定阈值事件，不是通关率；时间截断也不表示已经通关。

旧模型在相同当前窗口复测

算法	旧模型均分 $\pm$ SD	新模型均分 $\pm$ SD
DQN	2511.2 $\pm$ 543.8	18476.5 $\pm$ 1145.6
Double DQN	2988.0 $\pm$ 1280.5	18584.2 $\pm$ 1969.7

旧模型来自 405 $\times$ 720 历史训练，本次两代权重都在 683 $\times$ 871 和同一批 100 张测试图上评估。网络规模不变，但训练环境适配和整次重训不同，因此不能把提升单独归因于参数量或某一项修复。

曲线和失败诊断

每次检查点验证均分可能上下波动；best.pt 早于训练终点是允许的，仍应完成总预算。默认 DQN seed59 的验证集演示局 10019 得分 41949，而局 10000 得分 1565，因 blackhole 死亡。高分 GIF 是单个验证案例，不能替代保留测试均分，也不能掩盖失败。原计分与真实最高攀升需同时报告。

代码验收与复现步骤

agents.py 的 QNetwork、ReplayBuffer 和 dqn_update 实现网络、回放及 TD 更新；train.py 管理采样、验证和检查点。tests/test_agents.py 的独立构造案例给在线 $Q=[1,5,2]$ 、目标 $Q=[10,2,0]$ 、 $r=3$ 、 $\gamma=0.9$ ，此时 DQN 目标为 12，Double DQN 为 4.8；另验证真实终止目标为 3。

复现应使用独立 run-id，记录环境窗口、训练种子、实际决策数和权重选择标准。读取 results/native_v2/test_episodes.csv 可复算当前结果；根目录 results/test_episodes.csv 是历史实验，不用于本轮主比较。浏览器部署的 12 个新网络共 4320 组输入与 PyTorch 对照，argmax 不一致为 0。

实验依据：experiments/native_retrain_20261008/protocol.json；results/native_v2/summary.json；VERIFICATION.json。当前报告对应 native-viewport-v2，主窗口 683×871。

实际参与范围与复现记录

以下记录由署名成员根据真实工作填写，填写前不得把模块全部成果自动归为本人完成。

记录项	成员填写
本人实现或修改的文件与函数	_____
本人核对的理论与边界条件	_____
本人实际运行的命令与日期	_____
本人复核的模型或测试记录	_____
发现的问题与采用的修正	_____
本人参与的讲稿与报告部分	_____

成员应能解释模型输入、动作、奖励、数据划分，以及本模块至少一个失败边界。署名前核对项目记录，并使个人叙述与实际贡献一致。

参考资料

Mnih 等 Playing Atari with Deep Reinforcement Learning 2013

van Hasselt 等 Deep Reinforcement Learning with Double Q learning 2015

下一步可预先固定更多种子和 Q 偏差诊断；未完成的研究不写成本模块已经获得的结论。