

Doodle Jump 原版规则强化学习小组技术报告

课程：2026 秋研究生强化学习 小组成员：A、B、C、D

摘要与主要结论

项目将 takosenpai2687/doodle-jump 接入强化学习训练，保留固定提交的外观、物理、平台生成和计分。当前 683×871 原窗口完成三算法各三训练种子、每次 100 万决策，并增加三次 PPO 速度置零消融，共 1200 万决策、47938132 物理帧。保留评测及历史复测共 5400 局。

DQN、Double DQN、PPO 原窗口平均得分分别为 18476.5 ± 1145.6 、 18584.2 ± 1969.7 、 3944.8 ± 535.6 。Double DQN 均值仅高 107.7 分，约 0.58%，不足认定优于 DQN。学习模型均明显优于随机，但未超过未训练的物理规则参考。原版得分与最高攀升不是同一指标，持续攀升和复杂地图控制仍有改进空间。

原版来源与工程边界

固定提交 d4b6071813a9c1353267d53dcfa9d8abc3e5b2f4 的 21 个文件保存在 upstream，SHA256 与清单一致。浏览器直接执行原脚本、图片、音效和 render 函数；适配层增加种子、训练接口、观测、奖励和指标。Python 是原数值规则移植，并以未改动 JavaScript 为对照。未声称商业官方游戏复现或从屏幕像素端到端学习。

原平台全宽独立随机、普通/移动/易碎抽样及额外补层、弹簧和黑洞原条件均保留，未加入保证可解的约束。原顶部出生、固定阈值 300、弹簧碰撞使用平台尺寸，以及 forEach 中 splice/push 等行为没有被修复。改变这些规则需产生新环境版本和新实验。

四人模块与责任边界

模块	技术范围	主要交付
A	原版保留、种子、Python 环境与数值一致性	env.py、桥接层、原版对照
B	DQN 与 Double DQN 的实现和价值实验	TD 更新、六组价值模型
C	PPO、GAE 与速度置零消融	PPO 更新、六组策略模型
D	数据隔离、统计、浏览器推理与汇报	5400 局评测、材料和演示

姓名、学号与实际完成的贡献需由四位成员据实确认。模块划分是成果组织方式，不伪造人工实施或工时记录。

状态动作与奖励

reset(seed) 返回观测，step(action) 执行最多 4 个原物理帧。动作 0、1、2 为左、不动、右，直接设置横向速度。跌落和撞黑洞为真实终止；1500 决策为训练/AI 时限截断，手动试玩不限时。地图随机采用 uint32 LCG，只在原 setup/reset/draw 内替换 Math.random，策略采样独立。

209 维观测字段

对象与维数	字段顺序与精确定义
玩家 5 维	2x/W-1; y/H; vx/speed; vy/superjump; (spawn_y-y+scroll-maxheight)/H
平台 20×10 维	绕屏相对横坐标/W; 相对纵坐标/H; 平台宽度/W; 移动平台 vx/2; 普通、移动、易碎三种 one-hot; 弹簧存在; 弹簧相对平台中心的横向偏移/W; 平台有效标记
黑洞 4 维	绕屏相对横坐标/W; 相对纵坐标/H; 碰撞半径 30/W; 黑洞有效标记

W、H 是画布宽高，scroll 是累计滚屏距离，maxheight 是历史最高攀升。玩家第 5 项是当前攀升与历史最高的差值，而不是绝对高度。平台按 abs(platform_y-player_y) 排序；只取当前可见范围及边缘缓冲中的对象，最多 20 个，缺槽填 0。黑洞缺失时 4 项填 0。三类型标记分别对应原版 type=5、2、3。弹簧偏移是相对平台中心的位置，不能误写为绝对横坐标。

观测只包含当前可见对象，不传未来平台、随机状态或目标动作。每帧对象数量和排序会变化，无记忆网络接收局部结构信息，应描述为部分可观测问题的近似，而不是完整 Markov 状态。

优化目标和计分差异

奖励 $r = \Delta \text{原版 score} / 100 - 0.001 \cdot I(\text{死亡})$ 。原 score 在滚屏时逐个平台累计，保留其定义与显示。附加最高攀升为 $\max(0, \text{spawn_y} - y + \text{scroll})$ 的历史最大值，与得分分开记录，不将初帧阈值夹取当作向上进展。

TD 和 GAE 在真实终止时屏蔽下一价值，时间截断仍 bootstrap；任何重置阻断 GAE 跨回合递推。采用奖励缩放和死亡惩罚是训练接口选择，不是对原游戏计分的改写。高度奖励的优劣需要单独实验，当前没有做该奖励消融。

三种算法和网络

DQN 采用经验回放、目标网络、epsilon-greedy 和 Huber 损失，目标 $y=r+\gamma \times (1-\text{terminal}) \times \max Q_{\text{target}}(s_{\text{next}},a)$ 。Double DQN 只将下一动作选择换为 $\text{argmax } Q_{\text{online}}$ ，再由 Q_{target} 评估。两者网络均为 $209 \rightarrow 128 \rightarrow 128 \rightarrow 3$ ，共 43779 参数。

PPO 使用共享两层骨干、三动作策略头和标量价值头，共 43908 参数。策略目标用概率比与优势，并以 $\text{clip}=0.2$ 限制截断目标；GAE 由 TD 残差按 $\gamma \times \lambda$ 加权。价值头作为基线，浏览器只导出骨干和策略头，共 43779 参数。

配置项	DQN 与 Double DQN	PPO
gamma 与学习率	0.99; 0.0005	0.99; 0.0003
样本组织	回放 100000; batch128	8 环境×128步; minibatch256
数据复用	每4决策更新	每批4轮更新
目标与策略限制	每2000决策同步目标	ratio clip0.2
探索	epsilon 1→0.05, 60万步	按策略采样; 熵系数0.01
其他	2500步开始; 梯度范数10	lambda0.95; 价值系数0.5; 梯度范数0.5

训练预算与资源

主算法各三个种子 42、59、143，PPO 速度置零再三次，12 次各精确 1000000 决策。实际共 47938132 物理帧而非 48000000，因为死亡会提前结束动作重复。相同交互预算不意味着相同更新次数或计算量。

设备为 Intel i7-12700H、16 GB 内存、可用 RTX 3060 Laptop 6 GB。本轮采用 CPU，三训练进程并发，每进程一个 Torch 线程，float32。协议记录按 20k 决策计时试验选择 CPU；小 MLP 和 Python 环境下，GPU可用不意味着整条训练流水线更快。并发运行耗时不能作为独占设备性能结论。

真实版本、源码哈希、超参、实际决策数、物理帧、更新次数和耗时保存在每组 config.json 与 status.json。参数规模保持原两层 128，本轮没有扩大网络或使用更大模型成绩。

预先固定的评测协议

训练地图 seed $\geq$ 1000000。验证 10000-10019，每约 5 万决策按平均原版得分选 best.pt，final.pt 另存。当前窗口测试 61000-61099，desktop 62000-62099，mobile 63000-63099。每模型每场景 100 局，测试权重冻结，不根据测试调参。协议见 experiments/native_retrain_20261008/protocol.json，根目录旧协议不用于当前结果。

主比较统一 argmax；PPO 概率采样只作为原窗口诊断。39 组新策略 3900 局，随机/规则 600 局，旧模型同窗口 900 局，总计 5400。旧模型复测和主训练数据分开标识，避免新旧源稿混入汇总。

原窗口测试结果

策略	原版得分均值 $\pm$ 种子 SD	平均最高攀升 px	得分 $\geq$ 3000	时限截断
随机动作	262.5	14.3	0.0%	0.0%
物理规则参考	29765.8	6093.9	93.0%	40.0%
DQN	18476.5 $\pm$ 1145.6	3737.7	83.7%	19.7%
Double DQN	18584.2 $\pm$ 1969.7	3744.3	85.7%	19.7%
PPO	3944.8 $\pm$ 535.6	688.5	47.7%	15.0%

$\pm$ 是三个训练种子各 100 图均值之间的样本 SD，不是 300 回合置信区间。随机和规则没有训练种子，不伪造该 SD。得分 $\geq$ 3000 是阈值事件，不称通关率。物理规则参考使用同样局部观测和原尺度参数预测落点，未训练、未提供教师标签。

PPO 同权重采样得分 3576.4 $\pm$ 253.7，平均最高攀升 614.6 px，低于 argmax 主结果。当前配置下 DQN 和 Double DQN 得分接近，不能把平均排序强解读为普遍算法优势。仅三个独立训练种子不足以支持强统计或因果结论。

旧完整模型在当前同一窗口和测试地图的均分为 DQN 2511.2 $\pm$ 543.8、Double DQN 2988.0 $\pm$ 1280.5、PPO 2433.7 $\pm$ 498.1。旧训练来自 405 $\times$ 720；重训后的变化不是单一因素消融，不能归因参数量，因为本轮网络规模未变。

原窗口缩放适应和速度消融

算法	native 得分 $\pm$ SD	desktop 得分 $\pm$ SD	mobile 得分 $\pm$ SD
DQN	18476.5 $\pm$ 1145.6	19203.0 $\pm$ 743.4	14150.9 $\pm$ 1447.4
Double DQN	18584.2 $\pm$ 1969.7	16636.5 $\pm$ 1931.6	14735.1 $\pm$ 1057.8
PPO	3944.8 $\pm$ 535.6	3021.7 $\pm$ 283.6	3726.1 $\pm$ 188.7

native 画布 683×871，desktop 596.25×1060，mobile 390×844。窗口按原规则缩放，会影响布局、层数和固定300阈值的相对位置。不同窗口原版分数不是统一难度单位，应在同一窗口比较算法，不能将窗口差异单独归为泛化能力。

PPO 观测	native 得分 $\pm$ SD	desktop 得分 $\pm$ SD	mobile 得分 $\pm$ SD
完整速度	3944.8 $\pm$ 535.6	3021.7 $\pm$ 283.6	3726.1 $\pm$ 188.7
速度置零	4052.2 $\pm$ 184.4	2683.1 $\pm$ 352.4	3518.9 $\pm$ 444.2

消融把玩家 vx/vy 和平台 vx 特征置零，维数、网络、种子计划和预算保持一致，从头训练三个模型。native 置零均值高107.5分，另两个场景完整观测较高。没有预设必须下降，也没有足够种子支持速度有益或无益的强结论。局部无记忆观测和优化随机性可能共同影响结果，尚未做独立因果诊断。

演示和失败边界

默认 DQN seed59 只按验证选择。验证地图10019高分局为41949分、8619.2px；10000失败局为1565分、127.2px，撞黑洞死亡。GIF与截图来自实际浏览器权重推理，未编写路线。高分局代表可出现的行为，不代表平均稳定性；当前报告同时保留失败和测试平均。

未训练的物理规则参考均分仍高于学习算法，表明当前学习结果有空间。高得分不自动等同持续攀升；原生成规则、部分可观测、优化和奖励都可能影响表现，但当前证据不能指定单一原因。

一致性与部署验收

21个上游文件哈希一致。原JavaScript数值对照30条轨迹、81803物理帧；当前窗口另核对4202浏览器物理帧、800帧Python状态。七项边界覆盖弹簧、易碎、移动边界、黑洞、跌落、绕屏、数组刷新。五项算法单测独立检查TD目标、终止mask、GAE重置与时限、权重导出。

12个新网络各360观测，与PyTorch共4320组比较，最大绝对误差 1.1492×10^{-5} ，argmax不一致0。浏览器高分和失败轨迹计分、高度与Python完全一致。手动控制、暂停、重开和窄屏溢出也经过验证。这些验收用于声明实现正确性，不证明所有策略已经充分优化。

复现交付与课程要求

试玩通过 `start_game.cmd` 和本地 HTTP 服务运行；训练、评测、原版对照命令见 README。正式权重、配置、曲线、逐局CSV、原版快照和来源声明保留。当前逐局表为 `results/native_v2/test_episode.s.csv` 与 `baseline_episodes.csv`，旧根目录结果单独作为历史记录。

汇报约13分钟，需说明做什么、计划与实际效果、算法差异和每人技术模块；个人提交应核对真实署名与贡献。本项目四份个人PDF配同名Markdown，成员可补充自己实际参与的实现、复核、实验和写作工作。小组分工不替代真实个人贡献证明。

后续工作可预先规划更多训练种子、时序输入、高度奖励或视觉控制。规则修复和奖励修改应另行版本化，使用新训练和保留评测；未完成的实验不写成当前成果。

参考资料

[开源游戏固定提交](#)

[Mnih 等 Playing Atari with Deep Reinforcement Learning 2013](#)

[van Hasselt 等 Deep Reinforcement Learning with Double Q learning 2015](#)

[Schulman 等 Proximal Policy Optimization Algorithms 2017](#)

[Schulman 等 High Dimensional Continuous Control Using Generalized Advantage Estimation 2015](#)

实验依据：`experiments/native_retrain_20261008/protocol.json`；`results/native_v2/summary.json`；`VERIFICATION.json`。当前报告对应 `native-viewport-v2`，主窗口 683×871。